SUP DE VINCI

03 Novembre 2025

Projet d'études M1 DATA

MASTÈRE BIG DATA & IA

FORMATEUR : DIALLO ALIMOU

LES ETAPES CHRONOLOGIQUES DU PROJET

le 09 octobre 2025

MIse en place de l’environement

le 03 Novembre 2025

Data Ingestion — API, Authentification, Tokens

Data Ingestion

la source est l'API **Bluesky**.

Batch ingestion

→ Exécuter la collecte périodiquement (toutes les 5 minutes, toutes les heures…)

→ Parfait pour les réseaux sociaux

"**Toutes les 1 minute, récupérer 10 nouveaux posts de Bluesky.**"

Étapes de l’authentification Bluesky

Login avec identifiant + mot de passe

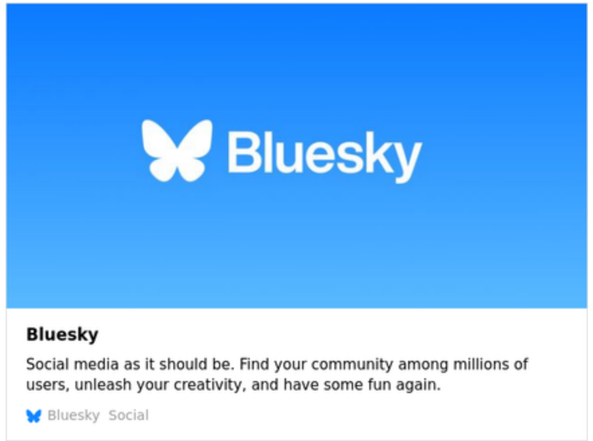

Bluesky vérifie :

- identifiant
- mot de passe

Si tout est correct, Bluesky te renvoie :

- accessJwt
- refreshJwt
- did
- handle

accessJwt

→ permet de faire des appels API authentifiés

→ c’est le “token d’accès”

refreshJwt

→ permet de régénérer un nouveau token si l’ancien expire

Rôle du accessJwt (le token)

Le token = ton ticket d’accès

```
(venv)
hp@santtoudllo MINGW64 ~/Desktop/sup de vinci/Supdevinci-2025-2026/M1/scr (main)
$ python login.py
HTTP status: 200
Login OK — tokens sauvegardés dans token.json
```

APRÈS LE TOKEN :

API renvoie 200 OK

✔ C’est le token qui te permet d’accéder à ta timeline privée.

✔ C’est lui que nous stockons dans token.json.

Schéma d'architecture (vue d'ensemble)

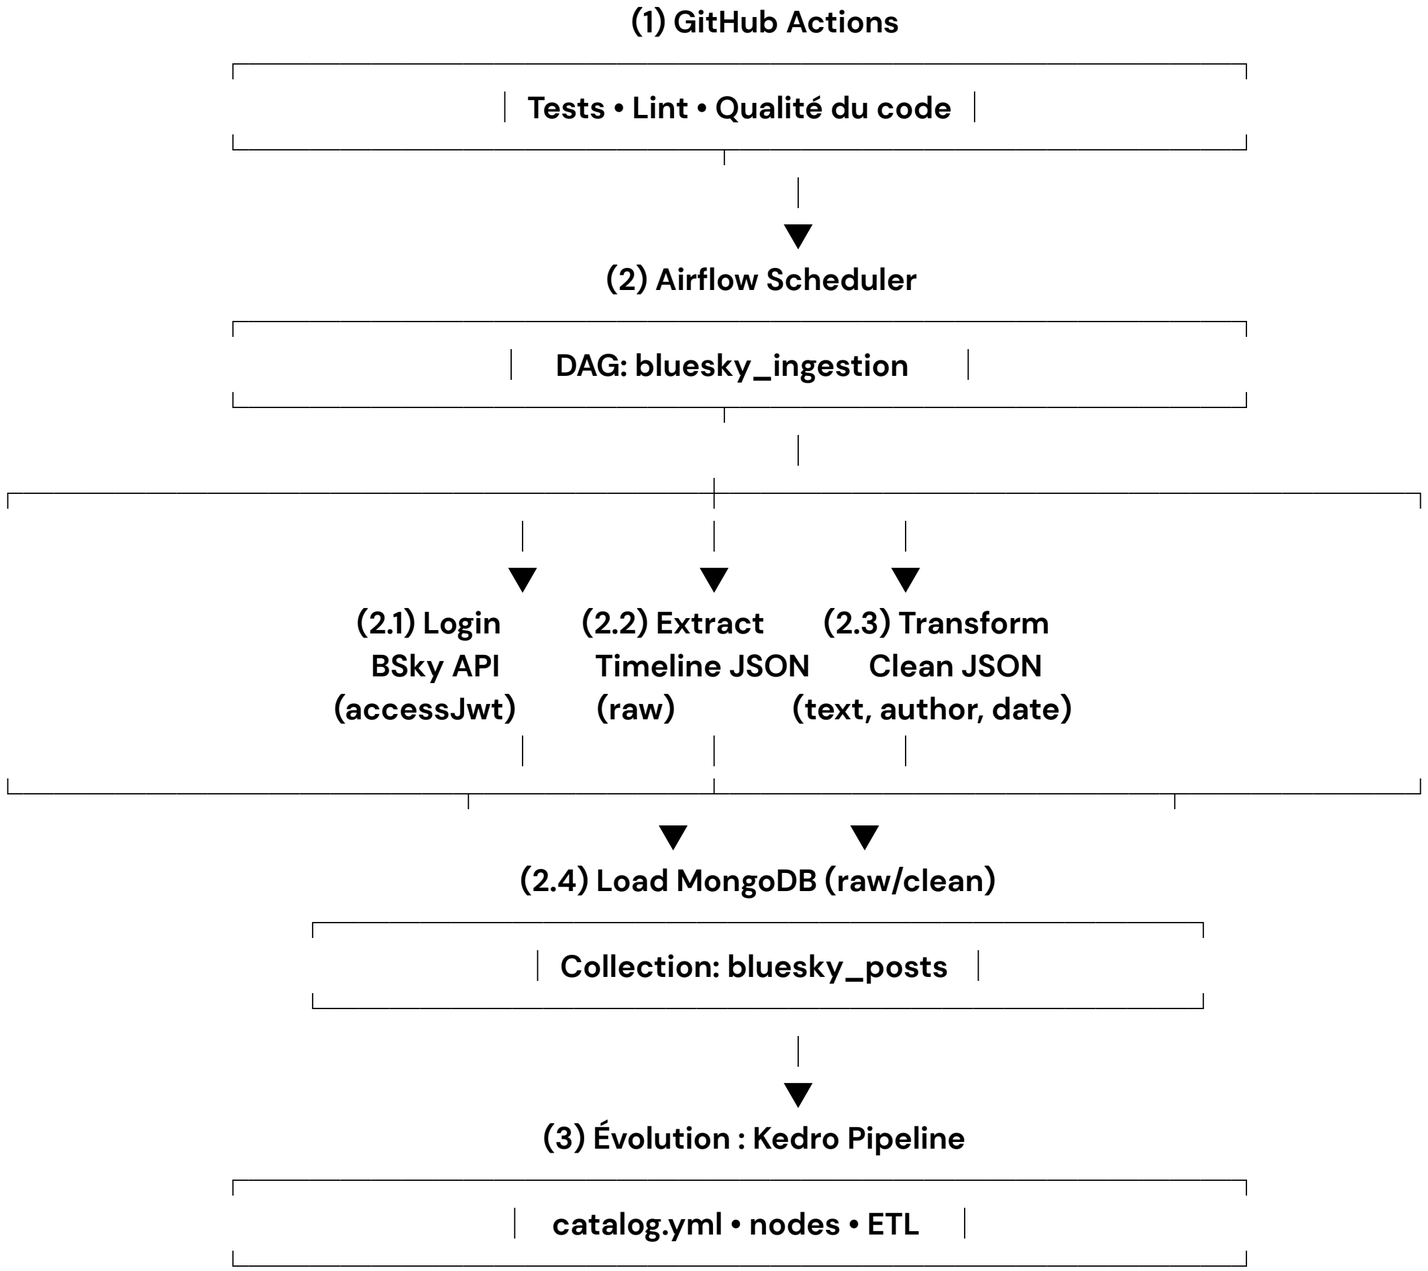

Version ULTRA SIMPLE

Bluesky API

▼

Python Scripts
(login + extract)

▼

Airflow DAG
(ETL automatisé)

▼

Clean JSON Data

▼

MongoDB Storage

▼

Kedro Pipeline
(ETL + NLP + Models)

▼

CI/CD: GitHub Actions

Apache Airflow

Apache Airflow est un outil d'orchestration pour automatiser, planifier et surveiller des pipelines de données.

Airflow = orchestrateur de **workflows**.

- Airflow ne fait pas l'ETL lui-même.
- Il coordonne les scripts Python, API, SQL, Spark, ML, etc.

Kedro

Kedro est un framework **structurel** pour la data science et les pipelines ML.

- L’objectif : donner une architecture professionnelle aux projets data.
- Kedro structure ton pipeline comme un projet software.

CI/CD avec GitHub Actions

GitHub Actions est une plateforme intégrée dans GitHub pour automatiser :

- les tests
- la qualité du code
- le déploiement
- les workflows Data / ML

GitHub Actions permet :

- Tester les scripts Python (API, transform, load Mongo)
- Tester les nodes Kedro
- Vérifier les DAG Airflow (syntaxe)
- Lancer un lint (flake8/black)
- Empêcher que du code cassé arrive en production
- Déployer automatiquement les mises à jour (optionnel)

C’est exactement le rôle d’une pipeline CI/CD moderne.

Construction du pipeline NLP avec Kedro

Pourquoi un pipeline NLP ?

Problème :

Le texte brut n’est pas directement utilisable pour l’analyse, encore moins pour détecter des fake n

Les posts contiennent :

- emojis
- hashtags #Election
- mentions @user
- URLs
- répétitions
- langues variées
- fautes, abréviations, spam

Le rôle du NLP est de transformer ce texte “sale” en données propres, standardisées et utiles.

On parle de prétraitement ou pipeline **NLP.**

Les étapes d’un pipeline NLP (ce que nous allons faire)

1. Extraction

Récupérer les posts depuis MongoDB.

Les étapes d’un pipeline NLP (ce que nous allons faire)

2. Nettoyage (cleaning)

- Suppression des URLs
- Suppression des mentions (@user)
- Suppression des hashtags (#keyword)
- Conversion en minuscules
- Retrait des emojis
- Retrait de la ponctuation

Objectif : rendre le texte propre et uniforme.

Les étapes d’un pipeline NLP (ce que nous allons faire)

3. Normalisation

- enlever les accents
- simplifier les caractères Unicode
- gérer les espaces

4. Tokenisation

Découper le texte en “mots”.

Exemple :

"Election fraud claims spreading" → ["election", "fraud", "claims", "spreading"]

5. Lemmatisation

Réduire chaque mot à sa racine :

- “running” → “run”
- “politicians” → “politician”

Pourquoi ?

Pour que le modèle comprenne que “run”, “running”, “runs” = même concept.

6. Vectorisation (option)

Transformer le texte en vecteurs numériques pour l’IA.

Kedro est un framework de data pipelines.

Il impose une structure claire et professionnelle :

- un pipeline est décomposé en nodes
- chaque node reçoit une entrée et produit une sortie
- tout est versionné et documenté
- les transformations sont traçables (lineage)
- on peut relancer n’importe quelle étape

Pourquoi Kedro ?

Dans notre projet, Kedro gère :

- chargement des données depuis MongoDB
- nettoyage du texte
- tokenisation & lemmatisation
- enregistrement du texte propre
- préparation pour le modèle de détection de fake news

Demarage kedro

1. Installation & initialisation de Kedro

```
kedro new --starter=spaceflights-pandas
```

2. Création du pipeline NLP

```
kedro pipeline create nlp_cleaning
```

Ce qui crée :

- src/bluesky_pipeline/pipelines/nlp_cleaning/
- conf/base/parameters_nlp_cleaning.yml

Exécution du pipeline

```
kedro run --pipeline nlp_cleaning
```